HTWG Konstanz

Interaktive Kontextkuratierung für Coding Agents

Ein transparentes, graphbasiertes Retrieval mit Human-in-the-Loop

Exposé zur Masterarbeit

Betreuer-Ausschreibung: *„Mehr Effizienz mit Coding Agents? Kontexttransparenz und Kontext-Engineering“*

Joschka Peeters

Matrikelnummer: 301750

27. Oktober 2026

Betreuer: Prof. Dr. Rainer Müller

Inhaltsverzeichnis

1 Problemstellung / Motivation **4**

1.1 Das Reaktivitätsproblem 5
1.2 Das Strukturproblem 5
1.3 Das Transparenzproblem 6
1.4 Zielsetzung 6

2 Forschungsstand **7**

2.1 Coding-Agents und der Aufgabenrahmen 7
2.2 Kontext als Erfolgsfaktor und Engpass 9
2.3 Graphbasierte Kontextbereitstellung 9
2.4 Grenzen langer, unstrukturierter Kontexte (Modellseite) 9
2.5 Nachvollziehbarkeit und menschliche Beteiligung 10

3 Abgrenzung **10**

3.1 Einleitung 10
3.2 Strang 1: Automatisches graphbasiertes Code-Retrieval 11
3.3 Strang 2: Interaktive Inspektion von Retrieval-Pipelines 12
3.4 Strang 3: Menschengestützte Interfaces für Wissensgraphen 13
3.5 Abgrenzung und Beitrag 14

4 Forschungsfragen **17**

4.1 Gestaltung des Artefakts 17
4.2 Wirkung der menschlichen Beteiligung 18
4.3 Wirkung auf den Agenten 20
4.4 Kosten der Kuratierung 21
4.5 Zuordnung 22

5 Methodisches Vorgehen **22**

5.1 Untersuchungsgegenstand und Bedingungen 23
5.2 Aufgaben und Referenzkontext 24
5.3 Evaluationsstufen 25
5.4 Ablauf der Nutzerstudie 26
5.5 Messgrößen 27
5.6 Auswertung 27
5.7 Gültigkeitsgrenzen 28

6 Zeitplan und Voraussetzungen **29**

6.1 Kritischer Pfad und Entscheidungspunkte 29
6.2 Voraussetzungen 30

Literaturverzeichnis **31**

1 Problemstellung / Motivation

Ziel dieser Masterarbeit ist die Entwicklung eines Systems, mit dem Softwareentwickler, die einen Coding-Agenten einsetzen, den Kontext, auf dem dieser arbeitet, vor der Ausführung prüfen und anpassen können.

Ein Coding-Agent ist eine auf einem Sprachmodell basierende Softwarekomponente, die Programmieraufgaben weitgehend selbstständig löst. Im Gegensatz zu klassischen Sprachmodellen, die primär eine direkte Antwort auf eine Eingabe generieren, verfolgen agentenbasierte Systeme einen mehrstufigen Lösungsansatz. Sie können Aufgaben selbstständig analysieren, weitere Verarbeitungsschritte planen, externe Werkzeuge verwenden, Befehle ausführen und die daraus gewonnenen Rückmeldungen in ihr weiteres Vorgehen einbeziehen (Xia u. a. 2024). In der Softwareentwicklung werden solche Agenten immer stärker eingesetzt. Vertreter wie OpenAI Codex und Claude Code navigieren durch ein Repository und schlussfolgern über mehrere Dateien hinweg. Sie sind damit nicht mehr bloße Assistenten, sondern eigenständige Beitragende (Lulla u. a. 2026).

Ein etablierter Maßstab dafür, wie gut solche Agenten Programmieraufgaben lösen, ist der SWE-bench-Benchmark: Er stellt Sprachmodelle vor reale Aufgaben aus der Softwareentwicklung, die in Form von GitHub-Issues dokumentiert sind. Das Modell erhält die Beschreibung des Issues und den zugehörigen Codebase-Stand und muss eine gezielte Änderung am Quellcode zur Behebung des Problems erzeugen (Patch), der die hinterlegten Tests besteht (Jimenez u. a. 2024).

Eine reale Codebase ist allerdings zu groß, um vollständig in das Kontextfenster des vom Agenten genutzten Sprachmodells zu passen (Jimenez u. a. 2024). Das Kontextfenster bezeichnet die in Tokens gemessene Textmenge, die ein Sprachmodell gleichzeitig verarbeiten kann (Du u. a. 2025). Wie gut ein Agent eine Aufgabe löst, hängt deshalb davon ab, welchen Ausschnitt er sich als Kontext heraussucht, denn auf diesem Kontext baut sein Schlussfolgern auf. Genau hier liegt aber eine Schwäche aktueller Agenten-Systeme: Sie rufen möglichst breiten Kontext ab, um nichts zu übersehen, beziehen dabei aber viel Rauschen ein und bleiben ungenau (Li u. a. 2026).

Diese Ungenauigkeit hängt somit nicht nur vom bloßen Umfang des abgerufenen Kontextes ab, sondern maßgeblich auch von der Art und Weise seiner Bereitstellung. Aus dieser ungesteuerten und rein automatischen Form der Bereitstellung ergeben sich drei Probleme, die in den folgenden Abschnitten einzeln behandelt werden. Der Abruf relevanter Code-Fragmente geschieht reaktiv während der Exploration durch den Agenten, indem er schrittweise auf Werkzeugausgaben und Fehlermeldungen reagiert, statt vorab zielgerichtet gesteuert zu werden (Reaktivitätsproblem). Um für die Bearbeitung einer Fragestellung aus dem zu großen Gesamtkontext die relevanten Teile auszuwählen, erstel-

len fortgeschrittene Ansätze einen Wissensgraphen, dessen struktureller Vorteil für die Kontextauswahl in Abschnitt 2.3 näher betrachtet wird. Dieser bildet die Code-Einheiten als Knoten und ihre Abhängigkeiten als Kanten ab und gewichtet algorithmisch, welche Teile für die Fragestellung relevant sind. Das Modell erhält anschließend die höher gewichteten Teile als Kontext. Dabei geht die im Graphen angelegte Beziehungsstruktur bei der Übergabe an das Modell teilweise wieder verloren, da sie zu flachen Listen komprimiert wird (Strukturproblem). Zudem bleibt für den Entwickler völlig offen, wie die zugrundeliegende Gewichtung und die daraus resultierende Auswahl genau zustande kommen (Transparenzproblem).

1.1 Das Reaktivitätsproblem

Wie aktuelle Coding-Agents ihren Kontext beschaffen, haben Li u. a. (2026) an Modellen wie GPT-5 und Claude Sonnet 4.5 untersucht. Dazu zeichnen sie die gesamte Trajektorie eines Agenten, also den vollständigen Ablauf seiner Schritte, auf und halten jede Code-Stelle fest, die er während der Bearbeitung reaktiv sichtet. Über alle untersuchten Modelle hinweg zeigt sich dasselbe Muster: Die Agenten rufen Code-Fragmente in einem zu großen Umfang ab und setzen auf Vollständigkeit statt auf Genauigkeit. Dies führt zu einem massiven Verbrauch an Token, wobei ein erheblicher Teil der abgerufenen Code-Fragmente letztlich überhaupt nicht zur Lösung beiträgt. Dass eine ungenaue Aufgabenstellung die Suche zusätzlich ausufern lässt, zeigen Suri u. a. (2026): In ihrem einführenden Beispiel durchsucht ein Agent ein Django-Repository 21 Schritte lang, ohne den Fehler zu beheben, während dieselbe Aufgabe mit einer präzisierten Beschreibung in sechs Schritten gelingt.

Verschiedene Ansätze bereiten den Kontext bereits vorab auf. *Agentless* (Xia u. a. 2024) grenzt die Fehlerstelle schrittweise ein, von der Datei über die Funktion bis zur einzelnen Zeile. *CodeScout* (Suri u. a. 2026) ergänzt die Aufgabenbeschreibung vorab um Hinweise aus dem Repository. Beide Ansätze laufen jedoch vollautomatisch ab: Welche spezifischen Codeabschnitte und technischen Details letztendlich an das Sprachmodell übergeben werden, entscheidet das System selbst und nicht der anwendende Entwickler.

1.2 Das Strukturproblem

Um die enorme Größe einer Datenbasis strukturiert zu bewältigen und präzise, nachvollziehbare Antworten zu ermöglichen, bieten Wissensgraphen (Knowledge Graphs) eine etablierte Alternative zu unstrukturiertem Text. Doch auch ein gut ausgewählter Kontext kann in einer strukturell ungünstigen Form beim Agenten ankommen. Pusch u. a. (2026)

beschreiben für wissensgraphenbasierte Retrieval-Augmented-Generation-Pipelines (KG-RAG), also Verfahren, die einem Sprachmodell vor der Antwortgenerierung passende Informationen aus einem Wissensgraphen abrufen und in den Kontext geben, das Problem, dass manche Systeme den Graphen vor der Übergabe in eine bloße, flache Liste von Subjekt-Prädikat-Objekt-Tripeln zerlegen, also in einzelne Aussagen, die je zwei Knoten über eine Beziehung verbinden, und diese an das Sprachmodell übergeben. Der resultierende Text wird dadurch sehr lang und bläht das Kontextfenster unnötig auf. Zudem geht die Beziehungsstruktur, die im Graphen ausdrücklich vorhanden war, verloren, sodass das Modell die relationalen Abhängigkeiten aus der Liste erst mühsam wieder erschließen muss.

1.3 Das Transparenzproblem

Um den Kontext eines Agenten mitgestalten zu können, muss man zuerst sehen, wie er zustande kommt. Genau hier setzen Pusch u. a. (2026) an und schlagen eine Lösung mit menschlicher Beteiligung vor. Das Sprachmodell formuliert die Anfrage an den Graphen und erklärt sie in verständlicher Sprache, der Nutzer gibt Rückmeldung, und beide verfeinern die Anfrage schrittweise gemeinsam. Der Mensch steuert dabei die Formulierung der Anfrage, nicht die daraus resultierende Auswahl der abgerufenen Knoten.

Für Coding-Agents gibt es inzwischen Werkzeuge, die die Trajektorie eines Agenten für dessen Entwickler aufbereiten, etwa *AgentStepper* (Hutter und Pradel 2026). Das Werkzeug stellt den Ablauf als strukturierte Konversation zwischen Sprachmodell, Agentenprogramm und Werkzeugen dar und zeigt neben den einzelnen Werkzeugaufrufen auch die schrittweisen Code-Änderungen des Agenten an. Sichtbar werden dabei ebenfalls die vom Sprachmodell ausgegebenen Begründungen, also die thoughts des Agenten. Ob diese Selbstauskunft mit dem tatsächlichen Auswahlmechanismus übereinstimmt, geht aus der Darstellung jedoch nicht hervor. Warum eine bestimmte Datei in den Kontext gelangt und eine andere unberücksichtigt bleibt, lässt sich anhand der Trajektorie nur begrenzt beurteilen. Hinzu kommt, dass das Werkzeug in erster Linie Entwickler des Agenten adressiert und nicht Nutzer, die einen Coding-Agent im Arbeitsalltag einsetzen.

1.4 Zielsetzung

Ziel dieser Arbeit ist die Entwicklung eines Systems, das Coding-Agents ihren Kontext über ein graphbasiertes Retrieval, also den gezielten Abruf passender Code-Teile aus dem Graphen, bereitstellt und den Softwareentwickler an jedem Schritt dieser Auswahl beteiligt. Grundlage ist ein Graph der Codebase, in dem Dateien, Funktionen

und ihre Abhängigkeiten als Knoten und Kanten liegen. Das Retrieval-Werkzeug ist über das Model Context Protocol (MCP) angebunden, einen offenen Standard, über den Coding-Agents externe Werkzeuge und Datenquellen einheitlich aufrufen können (Anthropic 2024). Ruft der Agent es auf, öffnet sich eine interaktive Oberfläche. Sie zeigt den abgerufenen Kontext als Graph und legt zu jedem Knoten offen, warum er abgerufen wurde. Das Retrieval läuft dort schrittweise ab. Das System ermittelt passende Knoten und folgt den Verbindungen zu weiterem zusammenhängendem Code. Der Entwickler prüft dabei jeden Schritt, wählt einzelne Knoten ab oder fügt weitere hinzu, ordnet sie nach Wichtigkeit und gibt die Richtung vor, etwa welche Startknoten den Ausgangspunkt bilden, welchen Abhängigkeiten gefolgt wird und wie weit, also über wie viele Hops. Erst wenn er die Auswahl bestätigt, geht der kuratierte Graph samt der vergebenen Priorisierung in strukturierter Form an den Agenten, der auf dieser Grundlage weiterarbeitet. Beim klassischen Retrieval-augmented Generation (RAG) wählt ein Retriever die Textausschnitte automatisch nach Ähnlichkeit aus und fügt sie direkt in den Prompt ein. Hier dagegen entsteht die Auswahl schrittweise und unter Steuerung des Entwicklers.

Damit greift der Ansatz die drei zuvor benannten Punkte auf. Der Entwickler gestaltet die Auswahl der benötigten Kontextbestandteile und ihrer Gewichtung, bevor der Agent damit weiterarbeitet, und muss den Ablauf nicht erst im Nachhinein nachvollziehen. Zu jedem Knoten ist sichtbar, warum er aufgenommen wurde, sodass die Auswahl nachvollziehbar bleibt. Die Beziehungsstruktur des Graphen wird bei der Übergabe nicht aufgelöst: Das Retrieval erschließt den Kontext als geordnete Traversierung entlang der Verknüpfungen, sodass zusammenhängender Code über die Kanten erreicht wird, statt den gesamten Kontext zu laden, und jeder Knoten trägt den Pfad seiner Aufnahme mit. Welche Wirkung diese Form und die vergebene Gewichtung auf den Agenten haben, ist Gegenstand von FF4 und FF5 und wird hier nicht vorweggenommen. Wie sich eine solche menschliche Kuratierung auf die Ergebnisse eines Coding-Agenten auswirkt, prüft die Arbeit in einer kontrollierten Studie, die das kuratierte Retrieval mit einem rein automatischen vergleicht.

2 Forschungsstand

2.1 Coding-Agents und der Aufgabenrahmen

Um Fortschritte beim automatischen Lösen realer Softwareentwicklungsaufgaben vergleichbar zu machen, hat sich SWE-bench als gemeinsamer Maßstab etabliert (Jimenez u. a. 2024). Der Benchmark umfasst 2.294 reale GitHub-Issues aus zwölf populären

Python-Repositories, jeweils zusammen mit dem Pull Request, der das Issue gelöst hat. Ein Issue ist dabei ein im Tracker des Repositories gemeldeter Fehler oder Änderungswunsch. Zu jeder Aufgabe erhält ein Modell die Beschreibung dieses Issues und das zugehörige Repository und muss den Code so ändern, dass er die hinterlegten Tests besteht. Als Lösungsrate wird der Anteil der Aufgaben angegeben, bei denen anschließend alle Tests erfolgreich durchlaufen. Die Aufgaben in SWE-bench verlangen häufig abgestimmte Änderungen über mehrere Funktionen, Klassen und Dateien hinweg sowie den Umgang mit langen Kontexten (Jimenez u. a. 2024).

Yang u. a. (2024) stellen mit *SWE-agent* ein System vor, das dem Sprachmodell Werkzeuge an die Hand gibt und es selbst entscheiden lässt, welche Schritte es geht. Damit ein Modell in der Umgebung des SWE-bench-Benchmarks zurechtkommt, legen sie eine Zwischenschicht zwischen das Modell und seine Arbeitsumgebung, das Agent-Computer-Interface. Sie stellt wenige klare Befehle zum Suchen, Öffnen und Bearbeiten von Dateien bereit und meldet nach jedem Befehl knapp zurück, was er bewirkt hat. Welche Vorteile diese Schicht liefert, zeigt sich am selben Basismodell: Ein nicht-interaktiver Abruf, der die passenden Dateien in einem Zug heraussucht und daraus direkt einen Patch erzeugt, löst korrekt rund 1,3 % der Aufgaben; mit dem schrittweisen Vorgehen über das Agent-Computer-Interface steigt die Lösungsrate auf 12,5 %. SWE-agent steht damit für das reaktive Vorgehen, bei dem der Agent selbst Dateien öffnet, nach passenden Stellen sucht und den nächsten Schritt anhand der Rückmeldung plant.

Xia u. a. (2024) hinterfragen mit Agentless den Nutzen einer autonomen Steuerung durch das Modell. Anstatt das System eigenständig explorieren zu lassen, geben sie einen festen, dreiphasigen Prozess vor: Zuerst wird die Fehlerstelle innerhalb der Codebase lokalisiert, anschließend ein Patch erzeugt und dieser abschließend mittels automatisierter Tests validiert. Die Lokalisierung arbeitet sich dabei von der Datei über die betroffene Klasse oder Funktion bis zur konkreten Editierstelle vor. Das Modell erledigt zwar die einzelnen Teilaufgaben, doch über die nächsten Schritte entscheidet es nicht selbst, und zu weiteren Werkzeugen greift es ebenfalls nicht. Auf SWE-bench Lite, einer Teilmenge des Benchmarks mit 300 Aufgaben, löst Agentless 32,0 % der Fälle. Der Unterschied der beiden Ansätze liegt in der Kontrolle über den Suchprozess. Während Coding-Agents während ihrer Laufzeit autonom explorieren und eigenständig entscheiden, welche Schritte sie als Nächstes unternehmen und welchen Code sie abrufen, folgt Agentless einer festen prozeduralen Steuerung. Der Spielraum des Sprachmodells ist dabei strikt auf die jeweiligen Phasen der Lokalisierung, Reparatur und Validierung begrenzt, wodurch das System den vordefinierten, sequenziellen Ablauf nicht verlassen kann.

2.2 Kontext als Erfolgsfaktor und Engpass

Wie gut ein Agent den passenden Kontext findet, lässt sich inzwischen für sich genommen messen. Li u. a. (2026) setzen mit ContextBench nicht am Endergebnis an, sondern am Abruf selbst, und werten dafür 1.136 Aufgaben aus 66 Repositories in acht Programmiersprachen aus. Ihr Befund: Agenten rufen eher zu breit ab, und aufwendigere Agentenarchitekturen verbessern die Qualität des Abrufs nur wenig. Dass eine gezielte Vorbereitung des Kontextes hilft, zeigen Suri u. a. (2026). Eine Voranalyse des Repositories vor der Bearbeitung hebt die Lösungsrate auf SWE-bench Verified, einer geprüften Teilmenge realer GitHub-Aufgaben, um rund 20 % relativ gegenüber demselben Verfahren ohne diese Voranalyse.

2.3 Graphbasierte Kontextbereitstellung

Eine strukturelle Antwort darauf fasst die Codebase nicht als lose Sammlung von Dateien auf, sondern als Graphen aus Code-Einheiten und ihren Beziehungen. Ouyang u. a. (2025) zeigen mit RepoGraph, dass ein solcher Graph sich als Zusatzmodul in bestehende Systeme einfügen lässt und deren Lösungsrate auf SWE-bench durchweg anhebt. KGCompass von Yang u. a. (2025) nimmt zusätzlich die Issues und Pull Requests eines Repositories in den Graphen auf, neben den Code-Einheiten wie Dateien, Klassen und Funktionen. Ausgehend von einer Fehlerbeschreibung führen die so entstandenen Verbindungen über mehrere Kanten hinweg zu den passenden Codestellen. Auf SWE-bench Lite löst KGCompass 58,3 % der Aufgaben, und von den Fehlern, die es lokalisiert, sind 89,7 % im Issue-Text nicht ausdrücklich genannt und nur über solche mehrstufigen Pfade im Graphen erreichbar.

2.4 Grenzen langer, unstrukturierter Kontexte (Modellseite)

Auch ein gut ausgewählter Kontext kann die Leistung mindern, sobald er unstrukturiert und umfangreich beim Modell ankommt. Der Grund liegt im Modell selbst. Liu u. a. (2023) beschreiben mit Lost-in-the-Middle, dass Modelle Angaben am Anfang und Ende einer langen Eingabe gut verwerten, in der Mitte dagegen spürbar schlechter, und das auch dann, wenn sie für lange Kontexte gebaut sind. Diese Positionsabhängigkeit betrifft nicht nur ältere Modelle. Wu u. a. (2025) führen sie theoretisch auf die Transformer-Architektur selbst zurück und reproduzieren dieselbe Verzerrung in aktuellen Sprachmodellen. Über die Position hinaus wirkt schon die schiere Länge: Du u. a. (2025) messen über mehrere Modelle hinweg, dass die Leistung mit wachsender Eingabe nachlässt, auch wenn alle nötigen Angaben enthalten sind und nichts Ablenkendes

hinzukommt.

2.5 Nachvollziehbarkeit und menschliche Beteiligung

Neben der Frage, welchen Kontext ein Agent nutzt, steht die Frage, ob sich sein Vorgehen überhaupt nachvollziehen lässt. Hutter und Pradel (2026) setzen hier mit AgentStepper an, einem interaktiven Debugger für Coding-Agents. Er macht die Trajektorie eines Agenten Schritt für Schritt sichtbar, seine Modellanfragen, Werkzeugaufrufe und Code-Änderungen, und man kann an einzelnen Stellen anhalten und eingreifen. Adressat ist der Entwickler, der den Agenten selbst prüfen und verbessern will. Das Werkzeug setzt damit nach der Ausführung an. Andere Forschungsansätze beziehen den Menschen bereits in die Phase der Kontextaufbereitung, das sogenannte Retrieval, ein. Dies geschieht etwa durch die manuelle Überprüfung abgerufener Textstellen (raggy, Romero Lauro u. a. 2025) oder durch die Unterstützung bei der Formulierung von Anfragen an Wissensgraphen (LinkQ, Li u. a. 2025; Pusch u. a. 2026). Inwiefern sich die vorliegende Arbeit von diesen und weiteren verwandten Ansätzen unterscheidet, wird im folgenden Kapitel dargelegt.

3 Abgrenzung

3.1 Einleitung

Diese Arbeit verbindet drei verschiedene Forschungsbereiche, die bisher unabhängig voneinander untersucht wurden. Der erste Bereich beschäftigt sich mit automatischem, graphbasiertem Code-Retrieval. Hier geht es um Systeme, die aus der vorhandenen Codebase einen Wissensgraphen erstellen, der dann vom KI-Modell abgefragt werden kann. Der zweite Bereich behandelt das Sichtbarmachen von Kontext-Retrieval-Pipelines für den Entwickler. Dazu gibt es verschiedene Werkzeuge, die das Retrieval für den Menschen nachvollziehbar machen. Es wird beispielsweise sichtbar gemacht, welche Textabschnitte (Chunks) bei einer RAG-Abfrage zurückgekommen sind und wie diese ausgewählt wurden. Der dritte Bereich behandelt menschengestützte Interaktion bei der Formulierung von Graph-Anfragen. Dabei hilft der Nutzer einem KI-Modell, eine korrekte Abfrage zu bauen, und prüft sie.

Die in den Abschnitten 2.3 und 2.4 dargelegten Befunde machen den strukturellen Vorteil einer graphbasierten Kontextbereitstellung deutlich. Im Unterschied zu einer flachen Übergabe, bei der relevante Code-Abschnitte unstrukturiert aneinandergereiht werden, speichert ein Wissensgraph Code-Einheiten als Knoten und ihre Abhängigkeiten

als typisierte Kanten. Ausgehend von identifizierten Einstiegspunkten lässt sich dem Graphen entlang seiner Kanten folgen und so gezielt weiterer zusammenhängender Code erschließen, ohne den gesamten Kontext laden zu müssen. Die im Code ausdrücklich vorhandene Beziehungsstruktur, zu der Aufrufketten, Importpfade und Klassenvererbungen zählen, bleibt dabei erhalten, statt vom Modell aus einer unstrukturierten Liste rekonstruiert werden zu müssen.

Diese drei Aspekte sind in der Forschung bislang getrennt voneinander untersucht worden.

3.2 Strang 1: Automatisches graphbasiertes Code-Retrieval

Es gibt eine Reihe von Systemen, die automatisches graphbasiertes Code-Retrieval durchführen. Dabei werden Code-Entitäten und Beziehungen in einem Graph gespeichert und dem Modell per Retrieval als Kontext bereitgestellt. Erstellung und Abfrage des Graphen ist dabei meist automatisiert. Das Tool RepoGraph (Ouyang u. a. 2025) erstellt automatisiert einen zeilengranularen Graphen, der den Code und seine Struktur repräsentiert. Der KI-Agent fragt den Graphen ab und bekommt für seine Anfrage einen Subgraphen mit den als relevant eingestuften Knoten als Antwort. Diese Informationen aus dem Subgraph werden dann in den Kontext des Agenten eingebunden. CodexGraph (Liu u. a. 2024) verwendet ebenfalls einen Wissensgraphen zur Repräsentation von Code. Dabei formuliert der Agent Graph-Abfragen aktiv, um seinen Kontext iterativ anzureichern. RANGER (Shah u. a. 2025) erweitert diesen Code-Graph-Ansatz auf einen repository-weiten Wissensgraphen bis auf Variablenebene. Er reichert die Knoten mit textuellen Beschreibungen und Embeddings (Vektordarstellungen von Text) an und übersetzt Nutzeranfragen zur Laufzeit in Cypher (der Abfragesprache von Neo4j, einer graphbasierten Datenbank). Codebase-Memory (Vogel u. a. 2026) geht einen ähnlichen Weg und baut seinen Code-Wissensgraphen mit tree-sitter auf, einem Parser, der Quellcode anhand seiner syntaktischen Struktur zerlegt. Bereitgestellt wird der Graph über das Model Context Protocol (MCP), worüber ein KI-Agent ihn mit strukturellen Anfragen wie Aufrufketten oder Impact-Analysen (welche Codeteile von einer Änderung betroffen sind) direkt durchsuchen kann. Von den hier genannten Systemen ähnelt dieser Ansatz dem in dieser Arbeit verwendeten Retrieval-Kern am meisten.

Kritische Einordnung: Diese Werkzeuge haben gemeinsam, dass das Retrieval vollständig automatisch läuft. Die Subgraphen werden automatisch erzeugt und gehen ohne menschliche Prüfung in den Kontext des KI-Modells bzw. -Agenten. Warum welcher Knoten für den Subgraphen ausgewählt wurde, wird dem Entwickler nicht offengelegt. Außerdem kann er vor der Generierung einer Antwort auf die gestellte Anfrage weder eingreifen noch die Auswahl der Knoten und Kanten im Subgraph verändern. Das in

dieser Masterarbeit entwickelte System setzt hier an: Es legt die Knotenauswahl dem Entwickler offen und ermöglicht ihm, sie vor der Übergabe an den Agenten interaktiv anzupassen.

3.3 Strang 2: Interaktive Inspektion von Retrieval-Pipelines

Grundgedanke: Die Retrieval-Stufe wird für Menschen sichtbar und prüfbar. Dieser Bereich befasst sich mit der Sichtbarmachung und Prüfung von Kontext-Retrieval-Pipelines. Die verschiedenen Werkzeuge sind: *raggy* (Romero Lauro u. a. 2025), *XGraphRAG* (Wang u. a. 2025) und *RAGAPHENE* (Fadnis u. a. 2025). *raggy* ist eine interaktive Oberfläche für Entwickler, die abgerufene Text-Chunks und Ähnlichkeits-Scores aus RAG-Anfragen sichtbar macht. *raggy* bietet dem Entwickler die Möglichkeit, Chunks manuell an- oder abzuwählen und die Retrieval-Parameter live anzupassen und zu optimieren. *XGraphRAG* überträgt diese Idee auf Graph-RAGs. Es arbeitet auf einem aus Text konstruierten Dokument-Graphen. Dabei wurde es explizit für Input-Tripel gebaut. Diese bestehen aus einer Frage, der Ground Truth (der als korrekt hinterlegten Antwort) und der Menge der Fakten (Graph-Elemente/Kanten), die die richtige Antwort stützen. Es vergleicht eine belegte, vor Ausführung bekannte, richtige Antwort mit der tatsächlichen Antwort des Graph-RAG. Es markiert beispielsweise Missing Recalls (was hätte abgerufen werden müssen, wurde aber nicht) und Unexpected Recalls (was fälschlicherweise abgerufen wurde) und verfolgt eine Antwort Schritt für Schritt durch die Retrieval-Pipeline. Es dient der Fehleranalyse der Graph-RAG-Pipeline und zeigt ihrem Entwickler, in welcher Phase eine Fehlinformation in den Subgraphen gelangte, beim Aufbau des Graphen oder beim späteren Abruf. RAGAPHENE verfolgt einen chat-basierten Annotationsansatz. Annotatoren prüfen dort die automatisch abgerufenen Passagen, verwerfen irrelevante, ergänzen fehlende und erzeugen die Antwort neu, korrigieren sie bei Bedarf von Hand und versehen sie mit Metadaten wie Fragetyp und Beantwortbarkeit. Ziel ist es, auf diese Weise Benchmark- und Evaluationsdaten für RAG-Systeme zu gewinnen.

Kritische Einordnung: Alle drei Werkzeuge, *raggy*, *RAGAPHENE* und *XGraphRAG*, haben gemein, dass sie für Entwickler oder Annotatoren gedacht sind und rückblickend arbeiten. Sie fragen, warum ein Ergebnis so zustande kam und nicht, wie sich der Kontext vorab formen lässt, auf dem ein Agent eine konkrete Aufgabe löst. Hinzu kommt ein Unterschied in der Datenstruktur: raggy und RAGAPHENE operieren auf Text-Passagen, ohne jede Graph-Traversierung. XGraphRAG arbeitet dagegen auf einem aus Text konstruierten Dokument-Graphen und nicht auf einem Code-Graphen. XGraphRAG setzt außerdem die richtige Antwort bereits voraus und eignet sich damit für die nachgelagerte Fehleranalyse, nicht für eine noch ungelöste Aufgabe. RAGAPHENE

wiederum erzeugt Annotations- und Evaluationsdaten und läuft damit außerhalb der eigentlichen Aufgabe eines Agenten. Und schließlich zielen alle drei auf allgemeine Dokument-Frage-Antwort-Probleme, nicht auf Code oder Coding-Agenten.

Trotz dieser Unterschiede ist gerade dieser Strang für die vorliegende Arbeit besonders aufschlussreich. Er zeigt, dass es sich lohnt, das Retrieval nicht als Blackbox zu behandeln, sondern den Menschen das Abgerufene prüfen und korrigieren zu lassen. Bei raggy und RAGAPHENE geschieht dies auf der Ebene der einzelnen abgerufenen Elemente. Dass dieser Bedarf real ist, belegt raggy empirisch: Die Teilnehmenden der Studie verlangten von sich aus nach mehr Klarheit darüber, warum ein Element überhaupt abgerufen wurde. Genau diesen Gedanken greift die vorliegende Arbeit auf und überträgt ihn von der rückblickenden Analyse auf die prospektive Kontextauswahl, von flachen Passagen auf einen Code-Graphen und von der Entwickler- bzw. Annotationsarbeit auf die laufende Aufgabe eines Coding-Agenten.

3.4 Strang 3: Menschengestützte Interfaces für Wissensgraphen

Ein dritter Forschungsbereich bezieht den Menschen in die Formulierung der Anfrage an einen Wissensgraphen ein. LinkQ (Li u. a. 2025) ist ein sprachmodellgestütztes visuelles Interface: Über ein mehrstufiges Protokoll überführt es eine natürlichsprachige Frage in eine wohlgeformte Anfrage in SPARQL (einer standardisierten Abfragesprache für Wissensgraphen) gegen den Wissensgraphen *Wikidata*. Damit der Nutzer die Anfrage auf Korrektheit prüfen und Fehler erkennen kann, zeigt LinkQ zwei Ansichten an, eine Entity-Relation-Tabelle und einen Query-Graphen (einer visuellen Darstellung der Anfrage).

Der in dieser Masterarbeit entwickelte Ansatz ähnelt am stärksten dem interaktiven Framework von Pusch u. a. (2026). Dieses Framework reagiert auf mehrere Schwächen bestehender Graph-RAG-Systeme. Manche graphbasierte Systeme vereinfachen den Wissensgraphen zu einer bloßen Liste von Einzelfakten, sodass seine Beziehungsstruktur verloren geht und das Sprachmodell die Abhängigkeiten aus der flachen Liste erst mühsam rekonstruieren muss. Andere finden die passenden Knoten über Ähnlichkeitsvergleiche, legen aber nicht offen, warum gerade diese gewählt wurden, sodass der Abruf eine Blackbox bleibt. In beiden Fällen ist der Nutzer nur passiver Empfänger und kann nicht mehr eingreifen, sobald Suche und Antwort laufen. Genau hier setzt das Framework an. Wie LinkQ beteiligt es den Menschen an der Formulierung der Datenbankabfrage, statt ihm nur eine fertige Antwort zu liefern, und macht den Weg von der Frage zur Antwort dabei sichtbar und korrigierbar.

Dazu verteilt das Framework die Arbeit auf vier aufeinander folgende Schritte. Zuerst

übersetzt ein Sprachmodell die in Alltagssprache gestellte Frage in eine passende Abfrage in der Graph-Abfragesprache Cypher (der Generator) und führt sie auf der Graphdatenbank aus (der Executor). Danach erklärt dasselbe Modell in einfachen Worten, was die Abfrage bewirkt, und weist auf Auffälligkeiten hin, etwa eine Beziehung, die in die falsche Richtung zeigt, oder einen Knotentyp, den es im Graphen gar nicht gibt (der Explainer). Stimmt etwas nicht, muss der Nutzer nicht von vorn anfangen. Er formuliert in Alltagssprache, was geändert werden soll, und das Modell passt nur die betroffene Stelle der Abfrage an, statt eine völlig neue zu erzeugen. Diesen nachbessernden Schritt nennen die Autoren den Amender.

So kann auch jemand einen Wissensgraphen nutzen, der die zugehörige Abfragesprache nicht beherrscht, und behält zugleich Überblick und Kontrolle darüber, wie die Antwort zustande kommt. Weil alle Ergebnisse aus dem geprüften Graphen stammen, sinkt außerdem die Gefahr, dass das Sprachmodell Fakten erfindet. Getestet haben die Autoren das System an einem eigens erstellten Film-Wissensgraphen sowie an zwei echten Graphen aus der Biologie und der Mathematik.

In beiden Fällen kontrolliert der Mensch die Anfrage an den Graphen, nicht die abgerufene Kontextmenge. Er beurteilt die erzeugte Anfrage und lässt sie bei Bedarf neu generieren. Einzelne abgerufene Knoten gezielt an- oder abzuwählen, gehört, soweit beschrieben, nicht zur Interaktion. Bei LinkQ kommen drei weitere Unterschiede hinzu. Das System nutzt kein Embedding-Retrieval, sondern löst die passenden Wikidata-Bezeichner über eine Fuzzy-Suche auf und konstruiert daraus die SPARQL-Anfrage. Sein Query-Graph zeigt den Aufbau der Anfrage in Form von Basic Graph Patterns, also den Tripelmustern, aus denen sie besteht, und nicht einen abgerufenen Subgraphen, der offenlegt, warum seine Knoten abgerufen wurden. Und die Evaluation bleibt begrenzt: Sie beruht auf einer qualitativen Studie mit fünf Teilnehmenden, während die Autoren einen quantitativen Vergleich mit klassischen Ansätzen des Natural Language Processing (NLP) und mit RAG selbst als offene Aufgabe nennen. Im Unterschied dazu ermöglicht das in dieser Masterarbeit entwickelte System dem Entwickler nicht nur, die Anfrage zu steuern, sondern den abgerufenen Subgraphen selbst zu prüfen, einzelne Knoten gezielt an- oder abzuwählen und ihre Gewichtung festzulegen.

3.5 Abgrenzung und Beitrag

Die vorliegende Arbeit führt diese drei zuvor getrennten Stränge zusammen. Vom ersten übernimmt sie das graphbasierte Code-Retrieval, vom zweiten die Idee, das Abgerufene für den Menschen sichtbar und prüfbar zu machen, vom dritten die menschliche Beteiligung am Abruf. Jeder Strang für sich deckt nur einen dieser Aspekte ab. Dort, wo sie sich überschneiden, setzt das hier vorgestellte System an: Es stellt einem Coding-Agenten

seinen Kontext über ein graphbasiertes Retrieval bereit und legt zu jedem Knoten offen, warum er abgerufen wurde. Bevor der Agent beginnt, kann der Mensch diese Auswahl prüfen und formen.

Die beiden zentralen Schwächen, die Pusch u. a. (2026) an bestehenden Graph-RAG-Systemen benennen, der undurchsichtige Abruf und die Passivität des Nutzers, decken sich genau mit der Motivation dieser Arbeit und werden durch den hier gewählten Ansatz gezielt adressiert.

Das in dieser Masterarbeit entwickelte System verwendet allerdings eine andere Vorgehensweise als Pusch u. a. Im Unterschied zu ihrem Ansatz behält es das embeddingbasierte Retrieval bei. Es macht für jeden Knoten nachvollziehbar, warum und wie er abgerufen wurde: Ähnlichkeits-Score, Schwellwert, Ablehnungsgrund, eingebetteter Text und der Pfad, über den er erreicht wurde. Kuratiert wird damit nicht wie bei Pusch u. a. die Anfrage, sondern der graphbasierte Abruf selbst: Der Entwickler steuert, welche Knoten die Suche seeden, welchen Verknüpfungen sie folgt und wie tief, und in welcher Reihenfolge die Knoten gewichtet in den Kontext gehen. Geformt wird auf diese Weise die Struktur des abgerufenen Subgraphen, nicht eine flache Kontextmenge. Die von Pusch u. a. beschriebene Opazität wird auf diese Weise nicht durch den Verzicht auf Embedding-Retrieval beantwortet, sondern dadurch, dass das Embedding-Retrieval transparent und für den Entwickler modifizierbar gemacht wird.

Das an anderen Systemen kritisierte Einebnen der Graphstruktur (Pusch u. a. 2026) ist dort eine Motivationsbehauptung, die die Autoren aus der Literatur weiterreichen, ohne sie selbst zu prüfen; sie wird hier deshalb nicht als Befund übernommen. Beschreibbar ist zunächst allein, was das vorgestellte System übergibt. Der kuratierte Subgraph geht dem Agenten nicht als undifferenzierter Text zu, sondern in einer Form, die in dieser Arbeit als *strukturerhaltend* bezeichnet wird und über drei Bestandteile definiert ist: Erstens trägt jeder Knoten den Pfad, über den er erreicht wurde, mit explizit typisierten Kanten wie CALLS oder IMPORTS. Zweitens wird die vollständige gerichtete Kantenmenge zwischen den ausgewählten Knoten ausgewiesen. Drittens sind die Knoten nach Traversierungsdistanz gruppiert, von den Einstiegspunkten über die direkten Abhängigkeiten bis zum transitiven Kontext.

Von diesen drei Bestandteilen trägt der dritte am wenigsten. Da die Traversierungsdistanz ohnehin an jedem Knoten vermerkt ist, kodiert die Gruppierung keine Angabe, die nicht auch ohne sie vorläge; sie ordnet an, statt Information hinzuzufügen. Das Gewicht liegt auf den ersten beiden Bestandteilen, denn Herkunftspfad und Kantenmenge sind aus einer bloßen Knotenliste nicht rekonstruierbar. Der Code selbst wird über Datei- und Zeilenreferenzen angesprochen und nicht vollständig in den Kontext übertragen, was zugleich das von Pusch u. a. beklagte Aufblähen des Kontextfensters vermeidet.

Ob diese Form dem Agenten gegenüber einer flachen Aufzählung desselben Knotensatzes nützt, wird in dieser Arbeit nicht vorausgesetzt, sondern in FF5 geprüft. Die Neuheit des Ansatzes liegt entsprechend nicht in der Behauptung, andere Systeme ebneten die Struktur ein und dieses tue es nicht – auch etablierte graphbasierte Verfahren übergeben typisierte und gewichtete Strukturen. Sie liegt darin, dass der strukturierte und gewichtete Subgraph vor der Übergabe vom Entwickler geformt wird, und darin, dass der Beitrag der Strukturerhaltung erstmals bei identischem Knotensatz und identischem Feldbestand auf Quellcode isoliert geprüft wird.

OFFEN – Belege für den vorstehenden Satz. Die Aussage „auch etablierte graphbasierte Verfahren übergeben typisierte und gewichtete Strukturen“ steht derzeit ohne Zitat und ist damit die schwächste Stelle der Abgrenzung. Zu prüfen und in `bibliography.bib` aufzunehmen sind mindestens: **GraphRAG** (Microsoft, Local Search übergibt Entitäten, Beziehungen und Community Reports als getrennte typisierte Recordtabellen mit Priorisierung und festen Token-Budgets je Typ), **LightRAG** (2024, duale Retrievalebene, Entitäten und Beziehungen als tabellarische Records) und **PathRAG** (Chen et al., arXiv 2502.14902, AAAI 2026, retrievt relationale Pfade statt Knoten und ordnet sie nach Zuverlässigkeit). Erst mit diesen Belegen ist begründet, warum die alte Formulierung „die anderen plätten, wir nicht“ aufgegeben wurde.

OFFEN – eingeräumte Gegenevidenz ergänzen. Der Absatz gewinnt erheblich, wenn der stärkste Gegenbefund selbst zitiert statt abgewartet wird: **Huang, Zhang, Mei, Ma**, „Can LLMs Effectively Leverage Graph Structural Information through Prompts, and Why?“, TMLR (arXiv 2309.16595). Befund dort: Entfernt man die expliziten Strukturmarker und linearisiert den Prompt, bleibt die Leistung nahezu gleich (71,1 % gegenüber 70,9 %); zufälliges Rewiring kostet LLMs 0,25 %, GNNs dagegen 5,55 %. Die Eingrenzung, die dagegen spricht, steht bereits fest und ist zu ergänzen: (a) dort ist die Kante ein Ähnlichkeitsproxy über Homophilie, bei einer Codeänderung dagegen der Aufgabeninhalt selbst; (b) Huang et al. messen einen Strukturnutzen gerade dort, wo der Knotentext dünn ist (+4,5 % bei „nur Titel“ gegenüber +1,1 % bei „Titel und Abstract“) – und genau das ist hier der Fall, weil Code über Datei- und Zeilenreferenzen statt im Volltext übergeben wird.

Der Retrieval-Kern des hier vorgestellten Systems steht den automatischen Code-Graph-Systemen aus dem ersten Strang nahe, am ehesten dem von Codebase-Memory. Der Unterschied liegt an anderer Stelle. RepoGraph, CodexGraph, RANGER und Codebase-Memory reichen den erzeugten Subgraphen unmittelbar an das Modell weiter. Das in dieser Masterarbeit entwickelte System schiebt davor einen Schritt, der die Auswahl sichtbar und veränderbar macht. Der abgerufene Subgraph wird dem Menschen gezeigt, zu jedem Knoten wird offengelegt, warum er abgerufen wurde, und er kann die Auswahl anpassen, bevor der Agent auf ihr arbeitet. Neu ist damit nicht, wie der Graph entsteht, sondern eine Transparenz- und Kontrollschicht über einem im Kern vergleichbaren

Abruf.

Auch das Verfahren XGraphRAG legt die Graphenstruktur offen und ermöglicht Modifikation der Struktur, scheidet aber für eine offene Aufgabe aus, da XGraphRAG die Kenntnis der richtigen Antwort voraussetzt und daher nur eine retrospektive Analyse erlaubt. In dem in dieser Masterarbeit entwickelten Verfahren setzt die Kuratierung des Kontext-Graphen an, bevor die Antwort feststeht. Der Kontext und seine strukturellen Verbindungen werden vor der Übergabe an den Agenten geformt, um durch eine verbesserte, strukturierte Kontextübergabe eine effizientere Lösung von Programmieraufgaben zu ermöglichen.

Das Forschungsfeld der Coding-Agents und graphbasierten Kontextbereitstellung entwickelt sich derzeit sehr dynamisch. Neue Systeme und Ansätze werden in kurzen Abständen veröffentlicht. Der in dieser Arbeit dargestellte Stand der Forschung sowie die vorgenommene Abgrenzung spiegeln den Zeitpunkt wider, zu dem das Thema dieser Masterarbeit festgelegt wurde. Später erschienene Arbeiten konnten nicht mehr vollständig berücksichtigt werden.

4 Forschungsfragen

Aus den drei in Abschnitt 1 dargelegten Problemen und der daraus abgeleiteten Zielsetzung ergibt sich die folgende Leitfrage:

> Wie wirkt sich eine transparente, schrittweise vom Entwickler kuratierte graphbasierte Kontextbereitstellung gegenüber einem rein automatischen Retrieval auf die Kontextgüte und die Aufgabenlösung eines Coding-Agents aus, und welcher Interaktionsaufwand entsteht dabei?

Die Leitfrage zerfällt in sechs Teilfragen. Die erste ist konstruktiver Natur und betrifft die Gestaltung des Artefakts; die übrigen fünf sind empirisch und werden über die in Abschnitt 5 beschriebenen Vergleiche beantwortet.

4.1 Gestaltung des Artefakts

Das Transparenzproblem verlangt, dass der Entwickler nicht nur das Ergebnis des Abrufs sieht, sondern dessen Zustandekommen. Daraus folgt:

> **FF1:** Wie ist ein graphbasiertes Retrieval zu gestalten, das zu jedem abgerufenen Knoten den Auswahlgrund offenlegt und die Auswahl vor der Übergabe an den Agenten schrittweise modifizierbar macht?

Als Auswahlgrund gelten der Ähnlichkeitswert des Knotens, die wirksame Schnittgrenze, im Ablehnungsfall der Grund der Verwerfung, der eingebettete Beschreibungstext sowie der Traversierungspfad, über den der Knoten erreicht wurde.

Konstruktionsfragen werden nicht über einen Bedingungsvergleich beantwortet. Das gestaltungsorientierte Vorgehen verlangt jedoch, dass ein Artefakt an vorab benannten Entwurfszielen geprüft wird (Hevner u. a. 2004); ohne solche Ziele bliebe FF1 eine Anforderungsliste ohne Kriterium für ihre Erfüllung. Für das hier entwickelte System gelten drei:

E1 Zu jedem Knoten des übergebenen Subgraphen ist der Auswahlgrund im oben genannten Umfang abrufbar, einschließlich der Gründe für verworfene Knoten.

E2 Jede Entscheidung des Abrufs — Einstiegspunkte, verfolgte Kanten, Traversierungstiefe, Auswahl und Gewichtung — ist vor der Übergabe an den Agenten veränderbar.

E3 Die offengelegten Begründungen werden bei der Kuratierung tatsächlich herangezogen.

E1 und E2 sind Eigenschaften der Konstruktion und werden durch die Beschreibung des Systems belegt. E3 ist es nicht: Ob die Offenlegung genutzt wird oder lediglich vorhanden ist, entscheidet sich am Verhalten der Entwickler. Dieses Ziel wird daher empirisch geprüft, über das Kuratierungsprotokoll, das laute Denken und den Interviewleitfaden der Nutzerstudie. Werden Ähnlichkeitswert und Traversierungspfad durchgängig übergangen, ist E3 verfehlt — ein Befund, der für die Gestaltung solcher Werkzeuge aufschlussreicher wäre als seine Bestätigung.

4.2 Wirkung der menschlichen Beteiligung

Ob Offenlegung allein genügt, ist eine empirische Frage. Romero Lauro u. a. (2025) berichten, dass Teilnehmende ihrer Studie von sich aus nach Begründungen für abgerufene Elemente verlangten; ob solche Begründungen dann auch zu besseren Urteilen führen, bleibt dort offen.

Dass ein Entwickler die automatisch erzeugte Auswahl überhaupt verbessern kann, ist dabei eine Annahme, die vorab zu benennen ist. Sie versteht sich nicht von selbst: Das Retrieval verfügt über Ähnlichkeitswerte, typisierte Kanten und den vollständigen Graphen, während der Entwickler nur einen Ausschnitt und wenige Minuten Zeit hat. Ein Beitrag ist deshalb nicht allgemein zu erwarten, sondern an zwei bestimmten Stellen.

Der erste liegt im Aussortieren. Zu erkennen, dass eine Codestelle der Aufgabenbeschrei-

bung zwar ähnelt, sachlich aber nichts mit ihr zu tun hat, ist eine Wiedererkennungsleistung: Sie setzt den Aufgabentext und die Beschreibung des Knotens voraus, nicht die genaue Kenntnis des Projekts. Genau dort liegt zugleich der in Abschnitt 2.4 belegte Hebel, denn dem Modell schadet weniger das Fehlende als das Mitgeführte (Du u. a. 2025; Liu u. a. 2023). Zu erwarten ist daher, dass die Kuratierung vor allem über das Entfernen wirkt und weniger über das Ergänzen.

Der zweite liegt in der Richtung der Suche. Der Entwickler bestimmt Einstiegspunkte, verfolgte Kanten und Traversierungstiefe. Dafür genügt ein grobes Verständnis davon, in welchem Teil des Systems die Aufgabe angesiedelt ist; einzelne Relevanzentscheidungen muss er dafür nicht treffen. Dieser Eingriff unterscheidet den hier verfolgten Ansatz von der bloßen An- und Abwahl bereits abgerufener Elemente.

Absicht und Projektkenntnis, die nicht in der Einbettung des Aufgabentextes stehen, kommen als dritter Beitrag hinzu, werden hier jedoch bewusst nachrangig angesetzt. Nicht die fachliche Qualifikation der Teilnehmenden ist dafür ausschlaggebend, sondern ihre Vertrautheit mit der konkreten Studien-Codebase, die allenfalls teilweise gegeben ist. Ein gemessener Effekt ist damit als untere Schranke dessen zu lesen, was auf vertrautem Code erreichbar wäre.

Diese Annahme bleibt prüfbar. Die in Abschnitt 5 beschriebene Zerlegung der optimierten Auswahl in Entfernen, Ergänzen und Umsortieren zeigt bereits vor der Erhebung, welcher Eingriff überhaupt wirkt. Wirkt allein das Ergänzen, ist der hier unterstellte Mechanismus widerlegt, und die menschliche Beteiligung wäre an einer anderen Stelle des Verfahrens anzusetzen. Daraus ergeben sich zwei Fragen:

> **FF2:** Wie nah kommt die Auswahl, die Entwickler anhand der offengelegten Begründungen treffen, an eine gegen den Referenzkontext optimierte Auswahl heran?
>
> **FF3:** Verändert die schrittweise Kuratierung die Güte des übergebenen Kontextes gegenüber einem automatischen graphbasierten Retrieval?

FF2 ist bewusst als Annäherungsfrage formuliert. Der Referenzkontext ist eine begründete Festlegung darüber, welche Codestellen eine Aufgabe erfordert, und kein von der Untersuchung unabhängiges Maß der Relevanz; eine an ihm optimierte Auswahl ist daher per Konstruktion optimal und nicht als empirischer Befund zu lesen. Gemessen wird folglich nicht die Richtigkeit menschlicher Relevanzurteile, sondern der Anteil des Spielraums, den Entwickler ausschöpfen: Bezugspunkte sind der automatisch abgerufene Ausgangszustand einerseits und die daran optimierte Auswahl andererseits. FF3 misst die Veränderung der Kontextgüte gegenüber dem unkuratierten Ausgangszustand.

4.3 Wirkung auf den Agenten

Eine verbesserte Kontextauswahl ist nur dann von Wert, wenn sie sich auf die Arbeit des Agenten überträgt. Getrennt davon steht die Frage nach der Übergabeform, die dem Strukturproblem entspringt:

> **FF4:** In welchem Umfang schlägt sich eine veränderte Kontextgüte auf einer kontrollierten Aufgabenmenge in Lösungsqualität, Schrittzahl und Tokenverbrauch des Agenten nieder?
>
> **FF5:** Wirkt sich eine strukturierte Übergabe des Subgraphen gegenüber einer flachen Liste desselben Knotensatzes auf die Aufgabenlösung aus?

Der Zuschnitt von FF4 auf eine kontrollierte Aufgabenmenge ist keine Abschwächung, sondern eine Angabe der Reichweite. Auf externem Material wird in dieser Arbeit ausschließlich die Güte des Abrufs gemessen; Lösungsraten auf etablierten Benchmarks gehören nicht zum Untersuchungsumfang. Da Lösungsqualität, Schrittzahl und Tokenverbrauch zudem gegenläufig ausfallen können, wird der Anteil erfüllter Akzeptanzkriterien vorab als vorrangige Zielgröße festgelegt; Schrittzahl und Tokenverbrauch werden nachgeordnet betrachtet und nur bei vergleichbarer Lösungsqualität als Effizienzgewinn gedeutet. Andernfalls ließe sich ein sparsamer Lauf nicht von einem vorzeitig abgebrochenen unterscheiden.

FF5 ist bewusst so geschnitten, dass zwischen den verglichenen Bedingungen sowohl der Knotensatz als auch der Feldbestand je Knoten identisch bleibt und sich ausschließlich Anordnung und Gruppierung unterscheiden. Diese zweite Bedingung ist nicht selbstverständlich: Eine Übergabe, die dieselben Knoten nur mit ihren Namen benennt, während die verglichene zusätzlich Dateipfad, Zeilenspanne und Beschreibung führt, unterscheidet sich nicht in der Form, sondern im Informationsgehalt, und ein dort beobachteter Unterschied wäre nicht der Darstellung zuzurechnen. Verglichen wird deshalb gegen eine flache Bedingung mit identischem Feldbestand und identischer Kantenmenge. Pusch u. a. (2026) beschreiben das Einebnen der Graphstruktur zwar als Problem, prüfen es aber nicht für sich genommen; ihre Beobachtung stammt zudem aus Dokumentgraphen und allgemeinen Frage-Antwort-Aufgaben, nicht aus dem Umgang mit Quellcode. Die in Abschnitt 2.3 angeführten Systeme verändern stets Abruf und Übergabeform zugleich, sodass sich der Anteil der Darstellung an einem beobachteten Unterschied dort nicht ablesen lässt.

OFFEN – Reichweite von FF5 ist kleiner, als sie klingt. Am 20.08.2026 am Werkzeug nachgemessen (21 Instanzen, identischer Knotensatz): Zwischen der gruppierten und der flachen Übergabe liegen bei gleichem Feldbestand nur rund 118 von 3.350 Token, also etwa 4 % – das sind die Abschnittsüberschriften und ihre Erklärzeilen. Alles Übrige, was die beiden Fassungen im Werkzeug heute trennt, sind Metadaten je Knoten und gehört nicht zur Form. FF5 fragt damit ehrlicherweise, ob rund 4 % Gerüst überhaupt eine Wirkung haben können. Vor der Erhebung zu entscheiden: entweder diese Reichweite hier ausdrücklich benennen, oder die Formseite substantieller fassen (etwa als Verschachtelung entlang der tatsächlichen Kanten statt als Gruppierung nach Hop-Distanz). Belegstelle: `docs/befund-2026-08-20-uebergabeform.md` im Werkzeug-Repository.
OFFEN – Gültigkeitsgrenze ergänzen. Formeffekte sind modellabhängig und nehmen mit der Modellstärke ab. Zu prüfen und als fünfte Gültigkeitsgrenze in Abschnitt 6 aufzunehmen, mit Beleg: He et al. 2024 („Does Prompt Formatting Have Any Impact on LLM Performance?“, arXiv 2411.10541: GPT-3.5-turbo variiert bis 40 %, GPT-4 deutlich robuster) und **Sclar et al.**, FormatSpread, ICLR 2024 (arXiv 2310.11324: bis zu 76 Accuracy-Punkte Spanne durch reine Oberflächenvariation). Ein FF5-Befund gilt danach für die eingesetzte Modellversion, nicht allgemein.

4.4 Kosten der Kuratierung

Menschliche Beteiligung ist nicht kostenlos. Ein Verfahren, das die Lösungsqualität geringfügig hebt, dafür aber erhebliche Entwicklerzeit bindet, ist im Arbeitsalltag nicht tragfähig. Daher:

> **FF6:** Welcher Interaktionsaufwand entsteht durch die Kuratierung, und wie bewerten Entwickler Nachvollziehbarkeit, Kontrolle und Vertrauenswürdigkeit des Verfahrens?

In FF6 steckt ein Zielkonflikt, der über die Messung von Zeit hinausgeht. Wer einen Agenten einsetzt, will Arbeit abgeben und gerade nicht jeden Schritt nachvollziehen; die Kuratierung verlangt aber genau diese Aufmerksamkeit. Ihr steht ein möglicher Nebennutzen gegenüber: Wer den Kontext selbst zusammenstellt, setzt sich dabei mit der Codebase auseinander und kennt sie hinterher womöglich besser. Ob die Teilnehmenden den Aufwand als Last oder als Gewinn beschreiben, ist deshalb Teil der Frage und nicht allein aus den Aufwandsmaßen abzulesen.

Die Kuratierung verschiebt den Eingriff zudem nach vorn. Statt ein Ergebnis im Nachhinein über Tests und Korrekturen zu berichtigen, wird die Arbeitsgrundlage vorab festgelegt. Dieselbe Abwägung ist aus der Zusammenarbeit menschlicher Entwicklungsteams vertraut, wo eine Einweisung zu Beginn dem späteren Nachbessern gegenübersteht. Ob dieser Vergleich trägt, wird im weiteren Verlauf anhand der Literatur zu Delegation

und Einarbeitung geprüft.

4.5 Zuordnung

Tabelle 1 ordnet jeder Teilfrage den Vergleich zu, über den sie beantwortet wird. Die Bezeichnungen der Bedingungen A bis D′ werden in Abschnitt 5.1 eingeführt.

	Frage	Vergleich	Stufe
FF1	Gestaltung des transparenten, modifizierbaren Retrievals	Artefakt, E1–E3	4
FF2	Nähe der Entwicklerauswahl zur optimierten Auswahl	D vs. D′	4
FF3	Veränderung der Kontextgüte durch Kuratierung	C vs. D, C vs. D′	1, 4
FF4	Wirkung auf Lösungsqualität, Schritte, Tokenverbrauch	A/B/C/D′; C vs. D	3, 4
FF5	Strukturierte gegenüber flacher Übergabe	B vs. C	3
FF6	Interaktionsaufwand und subjektive Bewertung	Nutzerstudie	4

Tabelle 1: Teilfragen und die zugehörigen Vergleiche

FF3 und FF5 zusammen erfüllen einen methodischen Zweck, der über die Einzelfragen hinausgeht. Der in dieser Arbeit vorgeschlagene Ansatz verbindet drei Bestandteile: das graphbasierte Retrieval, die Erhaltung der Struktur bei der Übergabe und die menschliche Kuratierung. Würden diese Bestandteile nur gemeinsam gegen einen Standardagenten geprüft, ließe sich ein beobachteter Unterschied keinem von ihnen zuordnen. Die getrennten Vergleiche stellen sicher, dass der Beitrag jedes Bestandteils einzeln ausgewiesen werden kann.

Ebenso ist vorab festzulegen, welches Ergebnis gegen die Annahme dieser Arbeit spräche. Bleibt der in Abschnitt 5 beschriebene Ausschöpfungsgrad nahe null und zeigt die kuratierte Bedingung gegenüber der automatischen keinen Vorteil beim Anteil erfüllter Akzeptanzkriterien, so gilt die Annahme, dass menschliche Kuratierung die Kontextbereitstellung verbessert, als nicht gestützt. Dieser Fall wird als Ergebnis berichtet und nicht durch nachträgliche Änderung der Auswertung umgangen. Die Aussagen zum Beitrag der Struktur (FF5) und zum Interaktionsaufwand (FF6) bleiben davon unberührt.

5 Methodisches Vorgehen

Die Arbeit folgt dem Paradigma der gestaltungsorientierten Forschung (Hevner u. a. 2004): Sie entwickelt ein Artefakt und prüft es anschließend gegen die Probleme, aus denen es hervorgegangen ist. Die Evaluation ist in vier Stufen gegliedert, die nach abnehmender Unabhängigkeit von externen Voraussetzungen angeordnet sind. Drei der

vier Stufen kommen ohne Versuchspersonen aus und sind beliebig wiederholbar; nur die vierte erhebt Daten mit Probanden.

5.1 Untersuchungsgegenstand und Bedingungen

Untersucht wird das in Abschnitt 1.4 beschriebene System in seiner schrittweisen Ausprägung, bei der das Retrieval in mehreren vom Entwickler bestätigten Zügen abläuft. Als Studiengegenstand dient *teamable-backend*, eine in Python geschriebene Django-Anwendung aus dem Umfeld der Hochschule, für die ein Codegraph aufgebaut wird. Die Wahl fiel auf dieses Projekt, weil es in der Lehre eingesetzt wird und die Teilnehmenden der Nutzerstudie darin bereits gearbeitet haben. Der eingesetzte Parser deckt Python ab; ein Wechsel der Zielsprache erfordert daher keine Anpassung des Artefakts.

Verglichen werden fünf Bedingungen, die sich in der Art der Kontextbereitstellung unterscheiden. Tabelle 2 fasst sie zusammen.

	Kontextbereitstellung
A	Standardwerkzeuge des Agenten, reaktive Exploration ohne Graph
B	Automatisches graphbasiertes Retrieval, flache Übergabe bei gleichem Feldbestand und gleicher Kantenmenge wie C
C	Automatisches graphbasiertes Retrieval, strukturierte Übergabe des Subgraphen
D	Schrittweise kuratiertes Retrieval, Auswahl durch den Entwickler
D′	Wie D, jedoch Auswahl automatisch gegen den Referenzkontext optimiert

Tabelle 2: Bedingungen der Untersuchung

Bedingung A bildet den in Abschnitt 2.1 beschriebenen reaktiven Fall ab und dient als Ausgangspunkt. Die Bedingungen B und C tragen denselben Knotensatz, denselben Feldbestand je Knoten und dieselbe Kantenmenge; sie unterscheiden sich allein darin, ob die Knoten nach Traversierungsdistanz gruppiert und geordnet sind. Damit isolieren sie den Effekt der Anordnung, ohne ihn mit einem Unterschied im Informationsgehalt oder in der Kontextlänge zu vermischen.

OFFEN – Bedingung B ist so noch nicht gebaut. Das Werkzeug kennt heute drei Ausgabeformen, und keine davon entspricht dem hier beschriebenen B: Die flache Fassung (`outputFormat: ßummary"`) führt weder Dateipfad noch Zeilenspanne noch Beschreibung und ist damit nicht formgleich, sondern informationsärmer – gemessen 530 gegenüber 3.350 Token bei identischem Knotensatz. Die kuratierte Fassung trägt als einzige die vollständige Kantenmenge, die der gruppierten Fassung fehlt. B im obigen Sinne (Feldbestand und Kanten wie C, nur ungeordnet und ungruppiert) muss vor der Erhebung erst implementiert werden; ebenso ist die Kantenmenge in C nachzuziehen. Andernfalls vergleicht FF5 Informationsgehalt statt Form und der Hauptvergleich C gegen D trennt vier Faktoren statt zwei. Stand und Umsetzungsplan: `docs/befund-2026-08-20-uebergabeform.md`, Arbeitspaket AP9.

Bedingung D′ ist keine reale Nutzungsform, sondern eine rechnerisch erzeugte Vergleichsgröße: Sie bildet ab, was eine Kuratierung unter Kenntnis des Referenzkontextes leisten würde, und liefert damit sowohl die Obergrenze des Verfahrens als auch den Bezugspunkt, an dem sich die Auswahl realer Entwickler in FF2 messen lässt.

Über alle Bedingungen hinweg werden Modellversion, Temperatur, Seed-Parameter des Retrievals, Traversierungstiefe, Systemprompt und der Ausgangszustand der Codebase konstant gehalten und je Durchlauf protokolliert.

5.2 Aufgaben und Referenzkontext

Für die Studie werden drei Aufgaben auf der Studien-Codebase entwickelt, die typische Wartungstätigkeiten abbilden. Damit die Kuratierung überhaupt wirksam werden kann, müssen die Aufgaben vier Eigenschaften erfüllen. Erstens ist die Problembeschreibung unscharf gehalten und benennt die betroffenen Codestellen nicht; dies entspricht dem von Suri u. a. (2026) beschriebenen Fall, in dem eine ungenaue Aufgabenstellung die Suche ausufern lässt. Zweitens enthält die Codebase zu jeder Aufgabe semantisch ähnliche, sachlich aber unbeteiligte Codestellen, an denen sich ein zu breiter Abruf zeigen kann. Drittens liegt ein Teil des benötigten Codes mindestens zwei Kanten vom naheliegenden Einstiegspunkt entfernt, sodass die Traversierung eine Rolle spielt. Viertens erstreckt sich die Lösung über mehrere Dateien.

Zu jeder Aufgabe wird ein Referenzkontext festgelegt, der die für die Lösung tatsächlich benötigten Dateien und Funktionen benennt. Er dient als Bezugsgröße für alle Maße der Kontextgüte und als Grundlage für die Bildung von Bedingung D′. Da sämtliche Aussagen über die Kontextgüte an ihm hängen, wird sein Zustandekommen offengelegt. Die Aufgaben werden aus der Versionsgeschichte des Studienprojekts abgeleitet: Ein abgeschlossener Änderungsvorgang liefert den Ausgangszustand der Codebase, die Aufgabenstellung und mit den darin geänderten Stellen den Kern des Referenzkontextes.

Ergänzt werden jene Stellen, die zum Verständnis der Aufgabe erforderlich sind, ohne selbst geändert zu werden; sie werden bei der eigenen Bearbeitung der Aufgabe protokolliert. Der Referenzkontext wird versioniert abgelegt, bevor das Retrieval auf der betreffenden Aufgabe erstmals ausgeführt wird, sodass eine nachträgliche Anpassung an beobachtete Ergebnisse ausgeschlossen ist. Für mindestens eine Aufgabe beurteilt der Betreuer den Referenzkontext unabhängig; der Grad der Übereinstimmung wird berichtet.

Die Akzeptanzkriterien jeder Aufgabe werden so formuliert, dass sie maschinell überprüfbar sind, da eine manuelle Prüfung bei der Zahl der automatisierten Durchläufe nicht praktikabel wäre.

5.3 Evaluationsstufen

Stufe 1: Bestimmung der Obergrenze. Zunächst wird geprüft, welchen Spielraum die Kuratierung überhaupt besitzt. Dazu wird der automatisch abgerufene Subgraph unter Kenntnis des Referenzkontextes bereinigt und ergänzt und der Agent auf dieser optimierten Auswahl laufen gelassen. Die Optimierung wird zusätzlich in ihre Bestandteile zerlegt, indem jeweils nur entfernt, nur ergänzt oder nur umsortiert wird. Damit lässt sich unterscheiden, ob eine mögliche Verbesserung auf einer höheren Genauigkeit, einer höheren Vollständigkeit oder allein auf der Reihenfolge beruht. Letzteres wäre ein unmittelbarer Beleg für die in Abschnitt 2.4 beschriebene Positionsabhängigkeit (Liu u. a. 2023; Wu u. a. 2025).

Diese Stufe steht bewusst am Anfang. Zeigt sich hier kein Spielraum, so wäre auch von der Erhebung mit Probanden kein Effekt zu erwarten, und das Aufgabenmaterial ist anzupassen, solange dafür noch Zeit bleibt.

Stufe 2: Abrufgüte auf externem Material. Um die Aussagen nicht allein auf eine selbst gewählte Codebase zu stützen, wird die Güte des Abrufs zusätzlich auf Instanzen aus SWE-bench Verified gemessen. Als Referenzkontext dienen dabei die im hinterlegten Lösungspatch geänderten Dateien und Funktionen. Gemessen wird ausschließlich der Abruf; die Aufgaben werden nicht gelöst und keine Tests ausgeführt. Als Vergleichsmaßstab dient eine reine Ähnlichkeitssuche ohne Traversierung, wodurch sich der Beitrag der Graphstruktur isolieren lässt.

Um den Aufwand des Graphaufbaus zu begrenzen, werden wenige Repositories mit jeweils mehreren Instanzen ausgewählt statt vieler einzelner Instanzen aus verschiedenen Repositories.

Stufe 3: Automatisierte Durchläufe. Die drei Aufgaben werden unter den Bedingungen A, B, C und D′ jeweils mehrfach automatisiert bearbeitet. Mehrfachdurchläufe sind erforderlich, da Agentenläufe auch bei gleicher Eingabe erheblich streuen. Erhoben werden die Erfüllung der Akzeptanzkriterien, die Zahl der Bearbeitungsschritte, der Tokenverbrauch und die Bearbeitungsdauer sowie die Güte des jeweils übergebenen Kontextes.

Stufe 4: Nutzerstudie. Die kuratierte Bedingung D wird mit Probanden erhoben und der automatischen Bedingung C gegenübergestellt. Sie ist als einzige Bedingung nicht automatisiert wiederholbar und daher in Stufe 3 nicht enthalten. Die Agentenmaße für D entstammen folglich Einzeldurchläufen je Person und Aufgabe; sie werden nicht mit den mehrfach besetzten Zellen der Stufe 3 zusammengefasst, sondern diesen gegenübergestellt. Um für D dennoch eine wiederholbare Messung zu erhalten, werden die in der Nutzerstudie erzeugten Auswahlen aufgezeichnet und anschließend unter den Bedingungen der Stufe 3 mehrfach nachgefahren. Damit lässt sich die Streuung der Agentenläufe von der Streuung zwischen den Teilnehmenden trennen.

5.4 Ablauf der Nutzerstudie

Vorgesehen sind die acht Studierenden eines Teamprojekts, das an der Studien-Codebase arbeitet. Die Gruppe ist fachlich heterogen zusammengesetzt: Ein Teil bringt einen Software-Engineering-Hintergrund mit, ein Teil nicht. Alle haben einen Workshop zu agentenbasierter Softwareentwicklung besucht und kennen den Umgang mit Coding-Agents daher aus eigener Anschauung.

Das Design ist als Messwiederholung angelegt: Jede Person bearbeitet zwei der drei Aufgaben, eine unter Bedingung C und eine unter Bedingung D. Aufgabe, Bedingung und Reihenfolge werden über die Teilnehmenden hinweg ausbalanciert. Bei kleiner Stichprobe ist dieses Vorgehen einer Aufteilung in getrennte Gruppen vorzuziehen, da jede Person als ihre eigene Kontrolle dient und die erhebliche Streuung zwischen Individuen dadurch nicht in den Vergleich eingeht.

Eine Sitzung dauert etwa 60 Minuten und gliedert sich in Einwilligung und Erhebung der Vorerfahrung, eine Einführung in Codebase und Werkzeug samt einer Übungsaufgabe, die beiden eigentlichen Aufgaben mit lautem Denken und Bildschirmaufzeichnung sowie einen Abschluss mit Fragebögen und einem halbstrukturierten Interview. Die Übungsaufgabe ist notwendig, damit die erste gewertete Aufgabe nicht überwiegend die Einarbeitung in die Oberfläche misst.

Neben den Verhaltensdaten werden die wahrgenommene Beanspruchung (Hart und

Staveland 1988), das Vertrauen in das System (Jian u. a. 2000) und die Gebrauchstauglichkeit (Brooke 1996) über etablierte Instrumente erhoben.

5.5 Messgrößen

Die Güte des übergebenen Kontextes wird als Genauigkeit und Vollständigkeit gegenüber dem Referenzkontext bestimmt, getrennt für Datei- und Funktionsebene. Ergänzend wird festgehalten, über wie viele Kanten die zutreffend abgerufenen Knoten erreicht wurden; ein hoher Anteil von Treffern jenseits der unmittelbaren Einstiegspunkte belegt den Beitrag der Traversierung.

Für die kuratierte Bedingung wird zusätzlich erfasst, welche Knoten der Entwickler zutreffend beziehungsweise fälschlich entfernt oder ergänzt hat. Als zentrales Maß für FF2 dient der Anteil des Spielraums, den die Kuratierung ausschöpft: die Verbesserung der Kontextgüte gegenüber dem automatischen Ausgangszustand, bezogen auf die unter Bedingung D′ überhaupt erreichbare Verbesserung. Fällt diese erreichbare Verbesserung auf einer Aufgabe gering aus, so ist FF2 auf ihr nicht sinnvoll zu beantworten; dies wird bereits in Stufe 1 sichtbar. Als Aufwandsmaße dienen die Dauer der Kuratierung, die Zahl der Eingriffe und der Anteil unverändert bestätigter Vorschläge.

Auf Seiten des Agenten werden die Zahl der Bearbeitungsschritte, der Tokenverbrauch, die Laufzeit und der Anteil erfüllter Akzeptanzkriterien erhoben. Vorrangige Zielgröße ist der Anteil erfüllter Akzeptanzkriterien; die übrigen Maße werden nachgeordnet und nur bei vergleichbarer Lösungsqualität als Effizienzgewinn gedeutet.

5.6 Auswertung

Die Stufen 1 bis 3 liefern beliebig wiederholbare Messungen und werden über Lage- und Streuungsmaße sowie gepaarte Vergleiche je Aufgabe ausgewertet. Für Stufe 2 werden Konfidenzintervalle über Resampling gebildet.

Für die Nutzerstudie ist bei fünf bis zehn Teilnehmenden keine belastbare Inferenzstatistik zu erwarten. Die Auswertung erfolgt daher deskriptiv und qualitativ; ein Rangtest für verbundene Stichproben wird ergänzend berichtet, trägt die Aussage aber nicht. Die Interviews werden transkribiert und thematisch codiert. Der quantitative Nachweis stützt sich auf die Stufen 1 bis 3, während die Nutzerstudie das Verhalten der Entwickler und dessen Begründungen erschließt.

5.7 Gültigkeitsgrenzen

Vier Einschränkungen sind bereits jetzt absehbar und werden in der Arbeit ausgewiesen.

Erstens sind die Teilnehmenden Studierende eines Masterstudiengangs der Softwaretechnik. Sie bringen die fachlichen Grundlagen mit, ihre Berufserfahrung streut jedoch und entspricht nicht der eines eingespielten Entwicklungsteams auf einer über Jahre gewachsenen Produktivcodebase. Für den in Abschnitt 4 angenommenen Wirkmechanismus ist ohnehin weniger die allgemeine Programmiererfahrung entscheidend als die Vertrautheit mit der Studien-Codebase: Das Aussortieren offensichtlich unbeteiligter Codestellen und das Vorgeben der Suchrichtung setzen vor allem den Aufgabentext voraus, während der Beitrag aus Projektkenntnis bei dieser Gruppe nur teilweise zum Tragen kommt. Beides wird über den Fragebogen zur Vorerfahrung erhoben und in der Auswertung berücksichtigt. Ein gemessener Effekt ist insoweit als untere Schranke zu lesen; eine Übertragung auf professionelle Entwicklungsteams ist nicht ohne Weiteres zulässig. Da die Teilnehmenden zudem einem Kurs des betreuenden Professors entstammen, werden Freiwilligkeit und die Entkopplung von jeder Leistungsbewertung schriftlich zugesichert.

Zweitens ist der Referenzkontext eine untere Schranke. Die in einem Lösungspatch geänderten Stellen sind nicht deckungsgleich mit dem Code, den man zum Verständnis einer Aufgabe benötigt. Die Vollständigkeit wird dadurch systematisch unterschätzt, allerdings über alle Bedingungen hinweg in gleicher Weise.

Drittens hängt die Wirksamkeit der Kuratierung von der Größe des Suchraums ab. In einer kleinen Codebase findet bereits das automatische Retrieval nahezu alles Relevante, sodass für eine Verbesserung wenig Raum bleibt. Ein in dieser Untersuchung gemessener Effekt wäre daher eher als konservative Schätzung zu lesen.

Viertens trifft die Arbeit keine Aussage über die Lösungsrate auf etablierten Benchmarks. Auf externem Material wird ausschließlich die Güte des Abrufs gemessen; Agentenläufe und Testausführung finden dort aus Aufwandsgründen nicht statt. Sämtliche Aussagen zur Wirkung auf die Aufgabenlösung stützen sich damit auf die drei kontrollierten Aufgaben der Studien-Codebase. Deren Aufgabenstellungen, Akzeptanzkriterien und Referenzkontexte stammen aus derselben Hand; die in Abschnitt 5.2 beschriebene Ableitung aus der Versionsgeschichte und die unabhängige Zweitbeurteilung begrenzen diesen Umstand, heben ihn aber nicht auf. Eine Übertragung auf Benchmarkergebnisse ist nicht zulässig.

6 Zeitplan und Voraussetzungen

Die Bearbeitungszeit beträgt drei bis vier Monate. Tabelle 3 verteilt die in Abschnitt 5 beschriebenen Arbeitsschritte auf fünfzehn Wochen, gerechnet ab der Anmeldung der Arbeit. Die Verschriftlichung läuft ab der ersten Woche durchgehend mit; der Theorieteil liegt mit diesem Exposé bereits weitgehend vor.

Woche	Hauptstrang	Parallel
1	Studien-Codebase prüfen, Graph aufbauen, Übergabeform für B und C festlegen, Änderungsvorgänge als Aufgabenkandidaten sichten	Messumgebung für Stufe 2 aufbauen
2	Artefakt härten: Protokollierung der Kuratierungsschritte, Export der Auswahl, Antwortzeiten	Stufe 2 (Abruf auf externem Material)
3	Drei Aufgaben auswählen und ausformulieren	Stufe 2 auswerten; Einwilligungsunterlagen einreichen
4	Referenzkontexte festlegen und versionieren, maschinelle Akzeptanzprüfungen	Automatisierung der Agentendurchläufe
5	Zweitbeurteilung der Referenzkontexte; **Stufe 1 (Obergrenze)**	Erzeugung der optimierten Varianten
6	Stufe 3 vorbereiten und starten	Rekrutierung der Teilnehmenden
7	Stufe 3 abschließen, Zwischenauswertung	Studienmaterial und Fragebögen
8	Pilotdurchlauf mit ein bis zwei Personen, Nachbesserung	
9–10	**Stufe 4 (Nutzerstudie)**	laufende Transkription
11	Erhobene Auswahlen unter den Bedingungen der Stufe 3 nachfahren	
12	Auswertung, quantitativ und qualitativ	
13–15	Verschriftlichung, Puffer	

Tabelle 3: Zeitliche Planung der Arbeitsschritte

6.1 Kritischer Pfad und Entscheidungspunkte

Studien-Codebase, Aufgaben mit Referenzkontexten, Stufe 1, Stufe 3 und Nutzerstudie bauen aufeinander auf; eine Verzögerung an einer dieser Stellen verschiebt alle nachfolgenden. Stufe 2 hängt dagegen an keinem der übrigen Schritte und dient als zeitlicher Puffer.

Zwei Entscheidungspunkte sind vorgesehen. In Woche 1 wird geprüft, ob die Studien-Codebase Größe, Verknüpfungsdichte und Beschreibungsgüte aufweist, die ein graphbasiertes Retrieval überhaupt sinnvoll machen; andernfalls ist die Codebase zu wechseln, bevor Aufgaben entstehen. In Woche 5 entscheidet Stufe 1 darüber, ob die Aufgaben überhaupt Spielraum für eine Kuratierung lassen. Zeigt sich dort keiner, werden die

Aufgaben angepasst, solange dafür Zeit bleibt; die geänderte Fassung wird dokumentiert und die ursprüngliche im Anhang ausgewiesen. Ab Woche 11 findet keine weitere Datenerhebung statt.

Gerät der Zeitplan in Verzug, wird die Zahl der Aufgaben von drei auf zwei gesenkt, nicht die Zahl der Wiederholungen je Bedingung: Ohne Wiederholungen ließe sich die erhebliche Streuung der Agentendurchläufe nicht von einem Effekt der Bedingung trennen. Sagen weniger als vier Personen zu, wird Stufe 4 als Fallstudie mit zwei bis drei Teilnehmenden geführt; die Aussagekraft der Arbeit ruht dann auf den Stufen 1 bis 3, die ohne Versuchspersonen auskommen.

6.2 Voraussetzungen

Ein Teil der benötigten Zuarbeit liegt außerhalb der eigenen Planung und ist deshalb frühzeitig zu klären. Vom Betreuer werden benötigt: der Zugang zur Studien-Codebase samt Versionsgeschichte, die schriftliche Zustimmung zu ihrer Verwendung, die Klärung, ob Codeausschnitte in der Arbeit abgedruckt werden dürfen, sowie die unabhängige Zweitbeurteilung eines Referenzkontextes in Woche 5. Die Einwilligungsunterlagen und der Umgang mit den Aufzeichnungen sind vorab mit der Hochschule abzustimmen. Die Ansprache der Teilnehmenden erfolgt aus den in Abschnitt 5 genannten Gründen nicht durch den Betreuer selbst und beginnt in Woche 6, damit fehlende Zusagen noch vor dem Pilotdurchlauf auffallen.

Auf technischer Seite müssen vor Stufe 3 die Übergabeformen der Bedingungen B und C denselben Knotensatz liefern, die Kuratierungsschritte maschinenlesbar protokolliert und einzelne Auswahlen exportier- und wieder einspielbar sein. Die Durchläufe der Stufen 1 und 3 sowie das Nachfahren in Woche 11 summieren sich auf rund einhundert Agentendurchläufe, deren Kosten vorab abzuschätzen sind.

Literaturverzeichnis

Anthropic (2024). *Model Context Protocol: An Open Standard for LLM Tool Integration*. Veröffentlicht November 2024. URL: https://modelcontextprotocol.io (besucht am 15. 07. 2026).

Brooke, John (1996). „SUS: A “Quick and Dirty” Usability Scale“. In: *Usability Evaluation in Industry*. Hrsg. von Patrick W. Jordan, Bruce Thomas, Bernard A. Weerdmeester und Ian L. McClelland. Taylor & Francis, S. 189–194.

Du, Yufeng u. a. (2025). *Context Length Alone Hurts LLM Performance Despite Perfect Retrieval*. arXiv: 2510.05381 [cs.CL]. URL: https://arxiv.org/abs/2510.05381.

Fadnis, Kshitij, Sara Rosenthal, Maeda Hanafi, Yannis Katsis und Marina Danilevsky (2025). *RAGAPHENE: A RAG Annotation Platform with Human Enhancements and Edits*. arXiv: 2508.19272 [cs.CL]. URL: https://arxiv.org/abs/2508.19272.

Hart, Sandra G. und Lowell E. Staveland (1988). „Development of NASA-TLX (Task Load Index): Results of Empirical and Theoretical Research“. In: *Human Mental Workload*. Hrsg. von Peter A. Hancock und Najmedin Meshkati. Bd. 52. Advances in Psychology. North-Holland, S. 139–183. DOI: 10.1016/S0166-4115(08)62386-9.

Hevner, Alan R., Salvatore T. March, Jinsoo Park und Sudha Ram (2004). „Design Science in Information Systems Research“. In: *MIS Quarterly* 28.1, S. 75–105. DOI: 10.2307/25148625.

Hutter, Robert und Michael Pradel (2026). *AgentStepper: Interactive Debugging of Software Development Agents*. arXiv: 2602.06593 [cs.SE]. URL: https://arxiv.org/abs/2602.06593.

Jian, Jiun-Yin, Ann M. Bisantz und Colin G. Drury (2000). „Foundations for an Empirically Determined Scale of Trust in Automated Systems“. In: *International Journal of Cognitive Ergonomics* 4.1, S. 53–71. DOI: 10.1207/S15327566IJCE0401_04.

Jimenez, Carlos E. u. a. (2024). *SWE-bench: Can Language Models Resolve Real-World GitHub Issues?* arXiv: 2310.06770 [cs.CL]. URL: https://arxiv.org/abs/2310.06770.

Li, Han u. a. (2026). *ContextBench: A Benchmark for Context Retrieval in Coding Agents*. arXiv: 2602.05892 [cs.LG]. URL: https://arxiv.org/abs/2602.05892.

Li, Harry, Gabriel Appleby und Ashley Suh (2025). *LinkQ: An LLM-Assisted Visual Interface for Knowledge Graph Question-Answering*. DOI: 10.1109/VIS55277.2024.00031. arXiv: 2406.06621 [cs.CL]. URL: https://arxiv.org/abs/2406.06621.

Liu, Nelson F. u. a. (2023). *Lost in the Middle: How Language Models Use Long Contexts*. arXiv: 2307.03172 [cs.CL]. URL: https://arxiv.org/abs/2307.03172.

Liu, Xiangyan u. a. (2024). *CodexGraph: Bridging Large Language Models and Code Repositories via Code Graph Databases*. arXiv: 2408.03910 [cs.SE]. URL: https://arxiv.org/abs/2408.03910.

Lulla, Jai Lal, Seyedmoein Mohsenimofidi, Matthias Galster, Jie M. Zhang, Sebastian Baltes und Christoph Treude (2026). *On the Impact of AGENTS.md Files on the Efficiency of AI Coding Agents*. arXiv: 2601.20404 [cs.SE]. URL: https://arxiv.org/abs/2601.20404.

Ouyang, Siru u. a. (2025). *RepoGraph: Enhancing AI Software Engineering with Repository-level Code Graph*. arXiv: 2410.14684 [cs.SE]. URL: https://arxiv.org/abs/2410.14684.

Pusch, Larissa, Alexandre Courtiol und Tim Conrad (2026). *A Human-in-the-Loop, LLM-Centered Architecture for Knowledge-Graph Question Answering*. arXiv: 2602.05512 [cs.CL]. URL: https://arxiv.org/abs/2602.05512.

Romero Lauro, Quentin, Shreya Shankar, Sepanta Zeighami und Aditya Parameswaran (2025). *RAG Without the Lag: Interactive Debugging for Retrieval-Augmented Generation Pipelines*. arXiv: 2504.13587 [cs.HC]. URL: https://arxiv.org/abs/2504.13587.

Shah, Pratik, Rajat Ghosh, Aryan Singhal und Debojyoti Dutta (2025). *RANGER – Repository-Level Agent for Graph-Enhanced Retrieval*. arXiv: 2509.25257 [cs.SE]. URL: https://arxiv.org/abs/2509.25257.

Suri, Manan u. a. (2026). *CodeScout: Contextual Problem Statement Enhancement for Software Agents*. arXiv: 2603.05744 [cs.CL]. URL: https://arxiv.org/abs/2603.05744.

Vogel, Martin, Falk Meyer-Eschenbach, Severin Kohler, Elias Grünewald und Felix Balzer (2026). *Codebase-Memory: Tree-Sitter-Based Knowledge Graphs for LLM Code Exploration via MCP*. arXiv: 2603.27277 [cs.SE]. URL: https://arxiv.org/abs/2603.27277.

Wang, Ke u. a. (2025). *XGraphRAG: Interactive Visual Analysis for Graph-based Retrieval-Augmented Generation*. arXiv: 2506.13782 [cs.IR]. URL: https://arxiv.org/abs/2506.13782.

Wu, Xinyi, Yifei Wang, Stefanie Jegelka und Ali Jadbabaie (2025). *On the Emergence of Position Bias in Transformers*. arXiv: 2502.01951 [cs.LG]. URL: https://arxiv.org/abs/2502.01951.

Xia, Chunqiu Steven, Yinlin Deng, Soren Dunn und Lingming Zhang (2024). *Agentless: Demystifying LLM-based Software Engineering Agents*. arXiv: 2407.01489 [cs.SE]. URL: https://arxiv.org/abs/2407.01489.

Yang, Boyang u. a. (2025). *Enhancing repository-level software repair via repository-aware knowledge graphs*. arXiv: 2503.21710 [cs.SE]. URL: https://arxiv.org/abs/2503.21710.

Yang, John u. a. (2024). *SWE-agent: Agent-Computer Interfaces Enable Automated Software Engineering*. arXiv: 2405.15793 [cs.SE]. URL: https://arxiv.org/abs/2405.15793.